


对极几何用来解决“根据两组2D特征匹配点来估计相机运动”的问题。

符号定义

假设我们从两张图像中，得到了一对正确配对的特征点。如下图，设第一帧到第二帧的运动为 R, t ， R, t （需要求解的变量）。两个相机中心分别为 O_1, O_2 。现在，考虑 I_1, I_2 中有一个特征点 p_1 ，它在 I_2 中对应着特征点 p_2 。这两个特征点通过特征匹配得到。



理想情况下，连线 $O_1 p_1 \rightarrow \overrightarrow{O_1 p_1}$

和连线 $O_2 p_2 \rightarrow \overrightarrow{O_2 p_2}$

在三维空间中会相交于点 P 。这时可以用一些术语来表示它们之间的几何关系：

- 极平面（Epipolar plane）： O_1, O_2, P 三个点构成的平面被称为极平面。
- 极点（Epipoles）： O_1, O_2 连线与成像平面 I_1, I_2 的交点 e_1, e_2 被称为极点。
- 极线（Epipolar line）：极平面与两个成像平面 I_1, I_2 之间的交线 l_1, l_2 被称为极线。
- 基线（Baseline）： $O_1 O_2$ 被称为基线。

几何关系

在第一帧的坐标系下，设 P 的空间位置为： $P = [X, Y, Z]^T$ ，那么由针孔相机模型可以得到两个像素点 p_1 和 p_2 的像素位置为：

$$s_1 p_1 = K P, s_2 p_2 = K (R P + t) \quad (1) \quad s_1 p_1 = K P, \quad s_2 p_2 = K (R P + t) \quad (2)$$

其中， K 为相机内参矩阵， R, t 为两个坐标系的相机运动。

我们通常会使用齐次坐标表示像素点。在使用齐次坐标时，一个向量将等于它自身乘上任意常数，这可以用于表示一个投影关系。比如， $s_1 p_1$ 和 p_1 成投影关系，它们在齐次坐标的意义是相等的，我们称这种关系为尺度意义下相等，记为：

$$s_1 p_1 = p_1 \quad (2) \quad s_1 p_1 = p_1$$

因此，可以将 (1) 中的投影关系用齐次坐标投影到归一化坐标上，写成：

$$p_1 = K P, p_2 = K (R P + t) \quad (3) \quad p_1 = K P, p_2 = K (R P + t) \quad (4)$$

然后取：

$$x_1 = K^{-1} p_1, x_2 = K^{-1} p_2 \quad (4) \quad x_1 = K^{-1} p_1, x_2 = K^{-1} p_2 \quad (5)$$

这里的 x_1, x_2 是两个像素点在归一化平面上的坐标。

带入 (3) 式，有：

$$x_2 = R x_1 + t \quad (5) \quad x_2 = R x_1 + t \quad (6)$$

两边同时左乘 t^T （相当于两边同时与 t 做外积），有：

$$t^T x_2 = t^T R x_1 \quad (6) \quad t^T x_2 = t^T R x_1 \quad (7)$$

然后，两侧同时左乘 x_2^T ：

$$x_2^T t = x_2^T R x_1 \quad (7) \quad x_2^T t = x_2^T R x_1 \quad (8)$$

观察等式左侧， $t^T x_2$ 是一个与 t 和 x_2 都垂直的向量。把它再和 x_2 做内积时，将得到 0。因此，有：

$$x_2^T t = 0 \quad (8) \quad x_2^T t = 0 \quad (9)$$

由于等式左侧严格为 0，乘以任意常数之后也都为 0，于是我们可以把 $=$ 写成等号：

$$x_2^T t = 0 \quad (9) \quad x_2^T t = 0 \quad (10)$$

重新代入 p_1 和 p_2 ，有：

$$p_2^T K^{-1} t = p_2^T K^{-1} R p_1 \quad (10) \quad p_2^T K^{-1} t = p_2^T K^{-1} R p_1 \quad (11)$$

(8) 和 (9) 这两个式子都称为对极约束，它以形式简洁著名。它的几何意义是 O_1, O_2, P 三点共面。

因为对极约束包含的未知数有旋转 R 和平移 t ，旋转和平移的自由度都为 3，由于尺度等价性，去掉一个自由度。因此，如果我们有 5 对以上匹配点，就可以通过这些二维图像点的对应关系，恢复出在两帧之间摄像机的运动。

本质矩阵和基础矩阵

对极约束中同时包含了平移和旋转。我们把中间部分记作两个矩阵：本质矩阵 E （Essential Matrix）和基础矩阵 F （Fundamental Matrix）。

基础矩阵：

$$E = t \wedge R(11) \quad E = t \wedge R(11)$$

本质矩阵：

$$F = K - TEK - 1(12) \quad F = K - TEK - 1(12)$$

因此，对极约束可以进一步简化为：

$$x_2^T E x_1 = p_2^T F p_1 = 0(13) \quad x_2^T E x_1 = p_2^T F p_1 = 0(13)$$

对极约束简洁地给出了两个匹配点的空间位置关系。于是，相机位姿估计问题变为以下两步：

1. 根据配对点的像素位置，求出 E 或者 F ；
2. 根据 E 或者 F ，求出 R, t 。

由于 E 和 F 只相差了相机内参，而内参在 SLAM 中通常是已知的，所以实践当中往往使用形式更简单的 E 。我们以 E 为例，介绍上面两个问题如何求解。

本质矩阵 E

由定义有，本质矩阵 $E = t \wedge R$ ，有以下性质：

- **尺度等价性**：本质矩阵是由对极约束定义的。由于对极约束是等式为零的约束，所以对 E 乘以任意非零常数后，对极约束依然满足。我们把这件事情称为 E 在不同尺度下是等价的。
- **本质矩阵的内在性质**：根据 $E = t \wedge R$ ，可以证明，本质矩阵 E 的奇异值必定是 $[\sigma, \sigma, 0]^T$ 的形式。
- **本质矩阵的自由度**：因为平移和旋转各有三个自由度，故 $t \wedge R$ 共有六个自由度。但由于尺度等价性，故 E 实际上只有五个自由度。

E 具有五个自由度的事实，表明我们最少可以用五对点来求解 E 。但是， E 的内在性质是一种非线性性质，在求解线性方程时会带来麻烦，因此，也可以只考虑它的尺度等价性，使用八对点来估计——这就是经典的八点法(Eight-point-algorithm)。然后对八点法进行奇异值分解，求解出最终值。

八点法求解本质矩阵 E

考虑一对匹配点，它们的归一化坐标为： $x_1 = [u_1, v_1, 1]^T, x_2 = [u_2, v_2, 1]^T$
 $x_1 = [u_1, v_1, 1]^T, x_2 = [u_2, v_2, 1]^T$ 。根据对极约束，有：

$$(u_1, v_1, 1)(e_1 e_2 e_3 e_4 e_5 e_6 e_7 e_8 e_9)(u_2, v_2, 1) = 0(14) \quad (u_1, v_1, 1)(e_1 e_2 e_3 e_4 e_5 e_6 e_7 e_8 e_9)(u_2, v_2, 1) = 0(14)$$

我们把矩阵 E 展开，写成向量的形式：

$$e = [e_1, e_2, e_3, e_4, e_5, e_6, e_7, e_8, e_9]^T(15) \quad e = [e_1, e_2, e_3, e_4, e_5, e_6, e_7, e_8, e_9]^T(15)$$

那么对极约束可以写成与 e 有关的线性形式：

$$[u_1 u_2, u_1 v_2, u_1, v_1 u_2, v_1 v_2, v_1, u_2, v_2, 1] \cdot e = 0 \quad [u_1 u_2, u_1 v_2, u_1, v_1 u_2, v_1 v_2, v_1, u_2, v_2, 1] \cdot e = 0$$

同理，对于其它点对也有相同的表示。我们把所有点都放到一个方程中，变成线性方程组：

$$(u_1 u_2, u_1 v_2, u_1, v_1 u_2, v_1 v_2, v_1, u_2, v_2, 1)(e_1 e_2 e_3 e_4 e_5 e_6 e_7 e_8 e_9) = 0(16) \quad (u_1 u_2, u_1 v_2, u_1, v_1 u_2, v_1 v_2, v_1, u_2, v_2, 1)(e_1 e_2 e_3 e_4 e_5 e_6 e_7 e_8 e_9) = 0(16)$$

上面的方程组可以通过 SVD 分解法解出，具体解法就不阐述了，见 SLAM 十四讲。

对极几何约束的局限性

尺度不确定性

由于本质矩阵 E 会有尺度等价性，所以它分解得到的 t 和 R 也会有尺度等价性。通常我们会把 t 进行归一化再进行求解。这样就会造成尺度不确定性。

初始化中的纯旋转

从 E 分解得到 R 和 t 的过程中，如果发生的是纯旋转，即 $t = 0$ ，那么也就无法退出 R 。

因此，在单目视觉的初始化中，必须要有一定程度的平移。

多于8点对的情况

当给定的点对数多于8对时，我们可以计算一个最小二乘解。

当可能出现误匹配的时候，更倾向于使用 RANSAC（随机采样一致性）的方法来求解。

参考文献：视觉 SLAM 十四讲