

0 摘要

本文提出了一种计算高效且鲁棒的激光雷达惯性里程计框架。我们使用**紧耦合的迭代扩展卡尔曼滤波 (IEKF)** 将激光雷达特征点与IMU数据融合，以便在可能会造成退化的快速运动、大量噪声或杂乱环境中进行稳健导航。为了在存在大量测量值的情况下降低计算量，我们提出了一个**新的公式来计算卡尔曼增益**。新公式的计算量取决于状态维数而不是测量维数。我们将所提出的方法进行了实现，并在各种室内外环境中进行了测试。在所有测试中，我们的方法都能够实时地产生可靠的导航结果：在四旋翼机载计算机上运行时，它在一次扫描中融合了1200多个有效特征点，并在25毫秒内完成一次IEKF步骤的所有迭代。我们的代码在Github上是开源的。开源地址为：https://github.com/bku-mars/FAST_LIO

I 引言

同时定位与建图 (SLAM) 是无人机 (UAV) 等移动机器人的基本前提。视觉 (惯性) 里程计 (VO)，如双目视觉里程计[1]和单目视觉里程计[2, 3]由于其重量轻且成本低，通常用于移动机器人。尽管提供了丰富的RGB信息，但视觉解决方案缺乏直接的深度测量，并且需要大量计算资源来重建三维环境以进行轨迹规划。此外，视觉方案对光照条件非常敏感。激光雷达 (LiDAR) 类传感器可以克服所有这些困难，但对于小型移动机器人来说成本太高 (并且体积太大)。

固态激光雷达是近年来激光雷达发展的主要趋势，如基于MEMS扫描[4]和基于旋转棱镜[5]的激光雷达。这些激光雷达非常具有成本效益 (成本接近全球快门相机)，重量轻 (可以由小型无人机携带)，并且高性能 (能够直接主动的进行远程的高精度三维测量)。这些特性使得此类激光雷达适用于无人机，特别是工业无人机，这些工业无人机需要获得精确的环境三维地图 (如航空测绘) 或者可能在具有严重照明变化的混乱环境中工作 (如灾后搜索和检查)。

尽管固态激光雷达具有巨大的潜力，但它给SLAM带来了新的挑战：

1. 激光雷达测量中的特征点通常是几何结构 (例如环境中的边缘和平面)。当无人机在没有强特征的杂乱环境中工作时，基于激光雷达的解决方案**很容易退化**。当激光雷达具有小视场时，这个问题更加明显。
2. 由于沿扫描方向的高分辨率，激光雷达扫描通常包含大量特征点 (例如成千上万个)。虽然这些特征点并不足以可靠地确定在退化情况下的姿态，但将如此大量的特征点与IMU测量进行紧耦合**需要巨大的计算资源**，这是无人机机载计算机无法负担的。
3. 由于激光雷达采样点是由几个激光探头和接收器依次发射和接收激光雷达进行采样的，所以一次扫描中的激光点总是在不同的时间被采样，这样会导致**运动畸变**，从而显著降低扫描配准[6]。无人机螺旋桨和马达的不断旋转也给IMU测量带来了显著的噪声。

为了使激光雷达导航能够适用于小型移动机器人 (如无人机)，我们提出了FAST-LIO，这是一个计算高效并且鲁棒的激光雷达惯性里程计功能包。更具体地说，我们的贡献如下：

1. 为了应对可能会造成退化的快速运动、大量噪声或杂乱环境，我们采用**紧耦合的迭代卡尔曼滤波IEKF**将激光雷达特征点与IMU测量值融合。我们提出了一种正式的反向传播过程，以补偿运动畸变；
2. 为了降低大量激光雷达特征点所带来的计算负载，我们提出了一个**新的公式来计算卡尔曼增益**，并证明了它与传统的卡尔曼增益计算公式等价。新公式的计算复杂度取决于状态维数而不是测量维数。
3. 我们将我们的公式应用到一个快速而鲁棒的激光雷达惯性里程计软件包中。该系统能够在小型四旋翼机载计算机上运行。
4. 我们在各种室内和室外环境中进行实验，并通过实际的无人机 (如图1) 飞行测试来验证系统在存在快速运动或强烈振动噪声时的鲁棒性。




Fig. 1. Our LiDAR-inertial navigation system runs on a Livox AVIA LiDAR³ and a DJI Manifold 2-C onboard computer⁴, all on a customized small-scale quadrotor UAV (280 mm wheelbase). The RGB camera is not used in our algorithm, but only for visualization. Video is available at <https://youtu.be/iYCY6T79oNU>

CSDN @威士忌燕麦拿铁

接下来的文章组织如下：第二节中，我们讨论了相关的研究工作。在第三节中，我们将对整个系统的pipeline进行概述并介绍每个关键组件的详细信息。第四节介绍了实验。最后在第五节进行总结。

II 相关工作

关于激光雷达SLAM的现有工作非常多。在此，我们将回顾最相关的工作：激光雷达里程计和建图、松耦合和紧耦合激光雷达惯性融合方法。

A 激光雷达里程计和建图

Besl等人[6]提出了一种用于扫描配准的迭代最近点方法 (ICP)，为激光雷达里程计奠定了基础。ICP方法在稠密三维扫描中表现良好。然而，对于激光雷达测量的稀疏点云，ICP方法要求的精确点匹配很少存在。为了解决这个问题，Segal等人[7]提出了一种基于点到平面距离的广义ICP方法。然后，Zhang等人[8]将这种ICP方法与点到边缘距离相结合，开发了激光雷达里程计和建图框架 (LOAM)。此后，基于LOAM出现了很多种改进方法，比如LeGO-LOAM[9]和LOAM-livox[10]。虽然这些方法在结构环境和大视场的激光雷达中表现很好，但它们非常容易受到缺少特征的环境或小视场激光雷达[10]的影响。

B 松耦合激光雷达惯导里程计

IMU测量通常用于减轻激光雷达在缺少特征的环境中退化的问题。松耦合激光雷达惯性里程计 (LIO) 方法通常分别处理激光雷达和IMU的测量结果，然后融合它们的结果。例如，使用IMU辅助的LOAM[8]将通过IMU测量值积分得到的位姿作为激光雷达扫描配准的初始估计。Zhen等人[11]使用误差状态EKF融合了IMU测量和激光雷达测量的高斯粒子滤波输出。Balazadeegan等人[12]增加了imu重力模型来估计六自由度自我运动，以辅助激光雷达扫描配准。Zuo等人[13]使用多状态约束卡尔曼滤波 (MSCKF) 将扫描配准结果与IMU和视觉测量结果融合。松耦合方法的一个常见步骤是通过对一个

描进行配准来获得位姿测量，然后将位姿测量与IMU测量融合。将扫描配准与数据融合分离，减少了计算负载。然而，它忽略了系统的其他状态（例如速度）和新扫描的位姿之间的相关性。此外，在缺少特征的环境下，扫描配准会在某些方向退化，导致后面步骤中不可靠的融合。

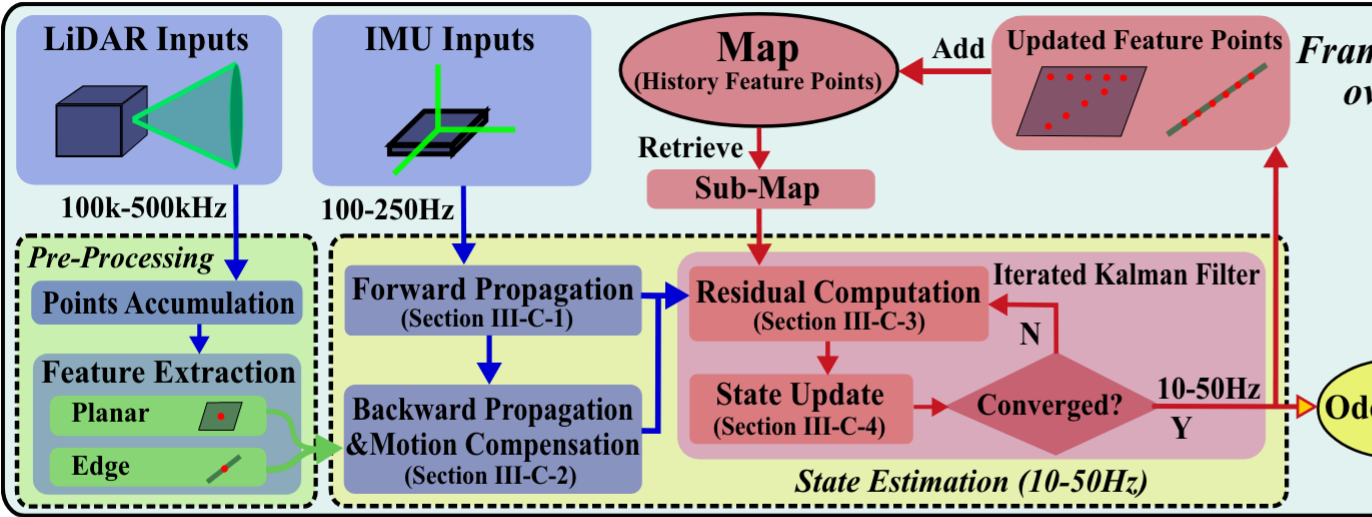
C 紧耦合激光雷达惯导里程计

与松散耦合的方法不同，紧耦合的激光雷达惯导里程计方法通常将激光雷达的原始特征点（而不是扫描配准结果）与IMU数据融合。紧耦合LIO主要有两种方法：基于优化的方法和基于滤波的方法。Geneva等人[14]利用IMU预积分约束[15]和激光雷达特征点的平面约束[16]进行图优化。最近，Ye等人[17]提出了LIO功能包，该包使用了类似的图优化方法，但基于边缘和平面特征。对于基于滤波器的方法，Bry[18]使用高斯粒子滤波器(GPF)来融合IMU和平面2D激光雷达的数据。该方法也被用于波士顿动力Atlas类人机器人。由于粒子滤波的计算复杂度随着特征点个数和系统维数的增加而快速增长，卡尔曼滤波及其变种通常更受欢迎，比如扩展卡尔曼滤波[19]、无迹卡尔曼滤波[20]、迭代卡尔曼滤波[21]等。

我们的方法属于紧耦合方法。我们采用类似于[21]的迭代扩展卡尔曼滤波器来减小线性化误差。卡尔曼滤波器（及其变体）的时间复杂度为 $O(m^2)$ ，其中 m 为测量维数[22]，这在处理大量激光雷达测量时可能导致非常高的计算负载。朴素的下采样将减少测量的数量，但以信息丢失为代价。类似[9]，[21]通过提取和拟合的地面来减少测量的数量。然而，这并不适用于总是在地上运行的航空应用。

III 方法论

A 框架概览



(a)

Fig. 2. System overview of FAST-LIO. (a): the overall pipeline; (b):

本文将使用表I中所示的符号。我们的工作概述如图2所示。激光雷达输入被送入特征提取模块，以获得平面和边缘特征。然后，将提取的特征和IMU测量值输入到我们的状态估计模块，以10Hz-50Hz的频率进行状态估计。然后，使用估计的姿态将特征点注册到全局帧，并将它们与从一开始构建的特征点地图进行合并。更新后的地图最终用于在下一步中注册更多的新点。

TABLE I
SOME IMPORTANT NOTATIONS

Symbols	Meaning
t_k	The scan-end time of the k -th LiDAR scan.
τ_i	The i -th IMU sample time in a LiDAR scan.
ρ_j	The j -th feature point's sample time in a LiDAR scan.
I_i, I_j, I_k	The IMU body frame at the time τ_i, ρ_j and t_k .
L_j, L_k	The LiDAR body frame at the time ρ_j and t_k .
$\mathbf{x}, \hat{\mathbf{x}}, \tilde{\mathbf{x}}$	The ground-true, propagated, and updated value of \mathbf{x} .
$\tilde{\mathbf{x}}$	The error between ground-true \mathbf{x} and its estimation $\hat{\mathbf{x}}$.
$\hat{\mathbf{x}}^\kappa$	The κ -th update of \mathbf{x} in the iterated Kalman filter.
$\mathbf{x}_i, \mathbf{x}_j, \mathbf{x}_k$	The vector (e.g., state) \mathbf{x} at time τ_i, ρ_j and t_k .
$\tilde{\mathbf{x}}_j$	Estimate of \mathbf{x}_j relative to \mathbf{x}_k in the back propagation.

CSDN @威士忌燕麦拿铁

- t_k : 第 k 次 Lidar 扫描的结束时间
- τ_i : 一次 Lidar 扫描中的 IMU 第 i 次采样时间
- ρ_j : 一次 Lidar 扫描中的第 j 个特征点的采样时间
- I_i, I_j, I_k : 分别表示在 τ_i, ρ_j 和 t_k 时刻的 IMU 坐标系
- L_j, L_k : 分别表示 ρ_j 和 t_k 时刻的 Lidar 坐标系
- $\mathbf{x}, \hat{\mathbf{x}}, \tilde{\mathbf{x}}$: 分别表示系统状态的真值、传播值和更新值

- $\mathbf{x} \sim \widetilde{\mathbf{x}}$

: 表示真值 x 和估计值 \overline{x} 之间的误差

- $x^\kappa \widehat{\mathbf{x}}^\kappa x$

κ : 表示迭代卡尔曼滤波第 k 次更新的状态传播值

- $x_i, x_i, x_k \setminus \{i\}, \setminus \{i\}, \setminus \{k\}$ x_i, x_k : 表示在 τ_i, ρ_j, τ_k 时刻的系统状态
- x_j^* : 表示在反向传播时, 与 x_k 相关的估计值 x_j^*

B 系统描述

1) \boxplus/\boxminus \boxplus/\boxminus 运算符:

记 M n 维流形空间, 比如: $M = S^3$. 由于流行在局部上和 R^n 是同胚 (homeomorphic) 的, 我们可以通过两个封闭运算符 \oplus 和 \ominus 来构建从 M 的一个局部邻域到它的正切空间 R^n 之间的双向映射[23]:

$$\boxplus: M \times R^n \rightarrow M; \boxminus: M \times M \rightarrow R^n \quad \boxplus: \mathcal{M} \times \mathbb{R}^n \rightarrow \mathcal{M}; \quad \boxminus: \mathcal{M} \times \mathcal{M} \rightarrow \mathbb{R}^n$$

$$M = \mathrm{SO}(3) : R \# r = R \operatorname{Exp}(\log(R)(r)) ; R1 \# R2 = \operatorname{Log}(\log(R2) \operatorname{TR}1) \cdot M = \mathrm{SO}(3) : \mathbf{R} \# \mathbf{r} = \mathbf{R} \operatorname{Exp}(\mathbf{r}) ; \mathbf{R}1 \# \mathbf{R}2 = \operatorname{Log}(\mathbf{R}2 \operatorname{TR}1)$$

$$M = Rn: \quad a \oplus b = a + b; \quad a \ominus b = a - b \quad \text{mathbb{R}}^n; \quad \text{mathbb{R}}^n \oplus \text{mathbb{R}}^n = \text{mathbb{R}}^n; \quad \text{mathbb{R}}^n \ominus \text{mathbb{R}}^n = \text{mathbb{R}}^n; \quad \text{mathbb{R}}^n \oplus \text{mathbb{R}}^n = \text{mathbb{R}}^n; \quad \text{mathbb{R}}^n \ominus \text{mathbb{R}}^n = \text{mathbb{R}}^n$$

其中, $\text{Exp}(\frac{\sqrt{2}}{2}(\tau)) = 1 + \tau // \tau \sin(\frac{\sqrt{2}}{2}(\tau // \tau)) + \tau 2 // 2(1 - \cos(\frac{\sqrt{2}}{2}(\tau // \tau)))$ $\text{Exp}(\frac{\sqrt{2}}{2}(\tau)) = \text{mathbf{f}}[\text{I}] + \text{frac}\{\text{mathbf{f}}[\text{r}]\}\{\backslash \text{mathbf{f}}[\text{r}]\}\backslash \sin(\frac{\sqrt{2}}{2}(\tau // \tau)) + \text{frac}\{\text{mathbf{f}}[\text{r}^2]\}\{\backslash \text{mathbf{f}}[\text{r}]\}\backslash (1 - \cos(\frac{\sqrt{2}}{2}(\tau // \tau)))$ $\text{Exp}(\tau) = 1 + \tau // \tau \text{rsin}(\tau // \tau) + \tau \tau / 2(1 - \cos(\tau // \tau))$ 是指数映射[23], $\text{Log}(\frac{\sqrt{2}}{2}(\cdot))$ 是其逆映射。对于复合流形: $M = \text{SO}(3) \times \mathbb{R}^n$

[illegible]

由上面的定义, 我们很容易证明:

$$(x \oplus u) \oplus x = u; x \oplus (y \oplus x) = y; \forall x, y \in M, \forall u \in Rn(\mathbf{mbf}\{x\} \boxplus \mathbf{mbf}\{u\} \boxminus \mathbf{mbf}\{x\} = \mathbf{mbf}\{u\}; \mathbf{mbf}\{x\} \boxplus (\mathbf{mbf}\{y\} \boxminus \mathbf{mbf}\{x\}) = \mathbf{mbf}\{y\}; \forall \mathbf{mbf}\{x\}, \mathbf{mbf}\{y\} \in \mathcal{M}, \forall \mathbf{mbf}\{u\} \in \mathbb{R}^{\wedge \{n\}} (x \oplus u) \oplus x = u; x \oplus (y \oplus x) = y; \forall x, y \in M, \forall u \in Rn$$

2) 连续模型:

假设IMU稳固的连接在了激光雷达上面,并且外参已知 $\text{ITL} = (\text{IRL}, \text{IpL}) \in \mathbb{R}^3 \times \mathbb{R}^3$ 。将IMU坐标系(记为 I1I)作为本体参考坐标系,从而可以推出动力学模型:

[illegible]

其中 $G_p I, G_R I \in \{G\}^{\text{matrix}}[p]_{-I}, \{G\}^{\text{matrix}}[R]_{-I}$ $G_p I, G_R I$ 分别表示 IMU 坐标系在世界坐标系下的位置和姿态（第一帧 IMU 坐标系表示世界坐标系，记为 $G G G$ ）， $G_g \in \{G\}^{\text{matrix}}[g]$ G_g 表示世界坐标系下未知的重力向量， $a_m \in \text{matrix}[a]_{-m}$ a_m 和 $\omega_m \in \text{matrix}[\omega]_{-m}$ ω_m 分别表示 IMU 加速度计和陀螺仪的测量值， $n_a \in \text{matrix}[n]_{-\text{matrix}[a]}$ n_a 和 $n_\omega \in \text{matrix}[n]_{-\text{matrix}[\omega]}$ n_ω 表示 IMU 测量的白噪声， $b_a \in \text{matrix}[b]_{-\text{matrix}[a]}$ b_a 和 $b_\omega \in \text{matrix}[b]_{-\text{matrix}[\omega]}$ b_ω 分别表示 IMU 加速度计和陀螺仪的偏置，分别建模为高斯白噪声 $n_b a \in \text{matrix}[n]_{-\text{matrix}[a]}$ $n_b a$ 和 $n_b \omega \in \text{matrix}[n]_{-\text{matrix}[b]_{-\text{matrix}[\omega]}}$ $n_b \omega$ 的随机游走过程。又乘运算符 $\square \sqcap \sqcup \lfloor \square \rfloor \wedge \square \sqcap \sqcup$ 表示为向量 $a \in R^{3 \times \text{matrix}[a]} \setminus \text{matrix}[R]^{\wedge \overline{\text{matrix}[3]}}$ $a \in R^3$ 的反对称矩阵。

3) 离散模型:

基于运算符 \boxplus ，我们可以使用零阶保持器（zero-order holder）将 IMU 采样周期 Δt 内的连续模型离散化。离散模型表示为：

$$x_{i+1} = x_i \oplus (\Delta t f(x_i, u_i, w_i)) \quad (2)$$

其中, i 是 IMU 测量的索引, 系统状态 \mathbf{x} 、输入 \mathbf{u} 和噪声项 \mathbf{w} 、函数 \mathbf{f} 定义如下:

[illegible]

$$M = SO(3) \times R^{15}, \dim(M) = 18 \times \begin{bmatrix} GRITGpITGvITb\omega TbaTGgT \end{bmatrix}^T \in \mathcal{M}u \doteq \begin{bmatrix} \omega mT a mT \end{bmatrix}^T, w \doteq \begin{bmatrix} n\omega T n a T n b \omega T n b a T \end{bmatrix}^T f(x_i, u_i, w_i) = \square$$

$$\square_{\text{omi}} - \text{bwi} - \text{noi} \text{GvliGRli}(\text{ami} - \text{bai} - \text{nai}) + \text{Gginbwinbai} 03 \times 1 \square \square (3)$$

4) 激光雷达点云预处理:

激光雷达点云测量包括其局部坐标系下的点云坐标。由于原始Lidar点的采样频率很高,所以不太可能对采样到的每个点都进行实时处理。在FAST-LIO中,设定了最小为20ms的数据采集间隔,即在一定时间内积累数据点,之后再一次性处理,这样使得状态估计(里程计输出)与地图更新最高可达50Hz。这样一组累积的点被称为一次扫描,这些点的处理时间记为 $t_{k1} t_{k2}$ (如图2(b))。

假设特征点的数量为 m 个，每个特征点的采样时间记为 $p_j \in [t_{k-1}, t_k]$ ， $p_j \in (t_{k-1}, t_k]$ 。特征点记为 $L_j p_j \in \mathcal{L}_j$ ， $L_j p_j \in \mathcal{L}_j$ ，其中 L_j 表示 p_j 时刻的Lidar局部坐标系。在一次Lidar扫描中，会有多个IMU测量，每个IMU测量的采样时间记为 $\tau_i \in [t_{k-1}, t_k]$ ， $\tau_i \in (t_{k-1}, t_k]$ ，每个IMU测量对应公式 (2) 中的一个状态 $x_i \in \mathcal{X}_i$ 。

需要注意的是, 最后一个Lidar特征点在一次Lidar扫描的最后时刻采样, 即 $\rho_m = t_k \cdot \rho_{\{m\}} = t_{\{k\}} \cdot \rho_m = t_k$; 但是IMU测量的时间不一定与一次Lidar扫描的开始或结束时间对齐。

C 状态估计

我们使用迭代扩展卡尔曼滤波IEKF进行状态方程(2)中的状态估计。此外我们在[23, 24]中表征了状态估计的切线空间中的估计协方差。

假设上一次激光雷达扫描在 $t_k - 1$ 时刻优化后的状态估计是 \hat{x}_{k-1} , 协方差矩阵为 P_{k-1} , 然后 P_{k-1} 表示下面定义的随机误差状态向量的协方差:

[illegible]

$$\overline{k-1} \doteq \overline{\text{ITGv}}$$

ITb

$$\begin{array}{c} \text{aTGg} \\ \hline \text{TIT} \end{array}$$

其中 $\delta\theta = \log \frac{\text{GRITGRI}}{\text{GRITGRI}} \Delta \theta = \log \frac{\text{GRITGRI}}{\text{GRITGRI}} \Delta \theta = \log \frac{\text{GRITGRI}}{\text{GRITGRI}} \Delta \theta$ 是姿态误差，剩下的都是标准加法误差（比如，状态 x 的估计值 \hat{x} 的误差为 $\tilde{x} = x - \hat{x}$ ）。直观上，姿态误差 $\delta\theta$ 描述了真实姿态和估计姿态之间的（微小）偏离。此处误差定义的主要优点是，它允许我们通过 3×3 协方差矩阵 $E\{\delta\theta\delta\theta^T\}$

