

卡尔曼滤波器

卡尔曼滤波器是[贝叶斯滤波器](#)在**线性高斯**系统下的一个特例。

假设线性高斯系统下运动模型和观测模型如下：

运动方程：
$$\mathbf{x}_k = \mathbf{A}_{k-1} \mathbf{x}_{k-1} + \mathbf{v}_k + \mathbf{w}_k, k = 1, \cdots, K$$
 观测方程：
$$\mathbf{y}_k = \mathbf{C}_k \mathbf{x}_k + \mathbf{n}_k, k = 0, \cdots, K$$

其中：

- $\mathbf{x}_k \in \mathbb{R}^N$ $\mathbf{x}_k \in \mathbb{R}^N$ 表示系统状态
- $\mathbf{v}_k \in \mathbb{R}^N$ $\mathbf{v}_k \in \mathbb{R}^N$ 表示输入
- $\mathbf{w}_k \in \mathbb{R}^N$ $\mathbf{w}_k \in \mathbb{R}^N$ 表示过程噪声， $\mathbf{w}_k \sim \mathcal{N}(\mathbf{0}, \mathbf{Q}_k)$ $\mathbf{w}_k \sim \mathcal{N}(\mathbf{0}, \mathbf{Q}_k)$
- $\mathbf{y}_k \in \mathbb{R}^M$ $\mathbf{y}_k \in \mathbb{R}^M$ 表示测量
- $\mathbf{n}_k \in \mathbb{R}^M$ $\mathbf{n}_k \in \mathbb{R}^M$ 表示测量噪声， $\mathbf{n}_k \sim \mathcal{N}(\mathbf{0}, \mathbf{R}_k)$ $\mathbf{n}_k \sim \mathcal{N}(\mathbf{0}, \mathbf{R}_k)$
- k 为时间下标，最大值为 K

用 $(\cdot)^{-}$ 表示先验，用 $(\cdot)^{+}$ 表示后验，卡尔曼滤波器则可以表示为：

预测

$$\mathbf{x}^{-}_k = \mathbf{A}_{k-1} \mathbf{x}^{-}_{k-1} + \mathbf{v}_k$$

$$\mathbf{P}^{-}_k = \mathbf{A}_{k-1} \mathbf{P}^{-}_{k-1} \mathbf{A}_{k-1}^T + \mathbf{Q}_k$$

卡尔曼增益

$$\mathbf{K}_k = \mathbf{P}^{-}_k \mathbf{C}_k^T (\mathbf{C}_k \mathbf{P}^{-}_k \mathbf{C}_k^T + \mathbf{R}_k)^{-1}$$

更新

$$\mathbf{x}^{+}_k = \mathbf{x}^{-}_k + \mathbf{K}_k (\mathbf{y}_k - \mathbf{C}_k \mathbf{x}^{-}_k)$$

$$(\mathbf{y}_k - \mathbf{C}_k \mathbf{x}^{-}_k)$$

$$\mathbf{P}^{+}_k = (\mathbf{I} - \mathbf{K}_k \mathbf{C}_k) \mathbf{P}^{-}_k$$

通过贝叶斯推断推导

预测

由于是线性高斯系统，因此直接将 $k-1$ 时刻的后验分布通过线性运动模型传递，即可得到 k 时刻的先验：

$$\mathbf{x}^{-}_k = \mathbb{E}[\mathbf{x}_k] = \mathbb{E}[\mathbf{A}_{k-1} \mathbf{x}_{k-1} + \mathbf{v}_k + \mathbf{w}_k] = \mathbf{A}_{k-1} \mathbb{E}[\mathbf{x}_{k-1}] + \mathbf{v}_k + \mathbb{E}[\mathbf{w}_k]$$

$$\mathbb{E}[\mathbf{x}_{k-1}] + \mathbf{v}_k + \mathbf{w}_k$$

$$\mathbb{E}[\mathbf{w}_k] = \mathbf{A}_{k-1} \mathbf{x}^{-}_{k-1} + \mathbf{v}_k$$

$$\mathbf{P}^{-}_k = \mathbb{E}[(\mathbf{x}_k - \mathbb{E}[\mathbf{x}_k])(\mathbf{x}_k - \mathbb{E}[\mathbf{x}_k])^T] = \mathbb{E}[(\mathbf{A}_{k-1} \mathbf{x}_{k-1} + \mathbf{v}_k + \mathbf{w}_k - \mathbf{A}_{k-1} \mathbf{x}^{-}_{k-1} - \mathbf{v}_k) \times (\mathbf{A}_{k-1} \mathbf{x}_{k-1} + \mathbf{v}_k + \mathbf{w}_k - \mathbf{A}_{k-1} \mathbf{x}^{-}_{k-1} - \mathbf{v}_k)^T] = \mathbf{A}_{k-1} \mathbb{E}[(\mathbf{x}_{k-1} - \mathbf{x}^{-}_{k-1})(\mathbf{x}_{k-1} - \mathbf{x}^{-}_{k-1})^T] + \mathbf{P}^{-}_{k-1} \mathbf{A}_{k-1}^T + \mathbf{Q}_k$$

$$\mathbb{E}[(\mathbf{x}_{k-1} - \mathbf{x}^{-}_{k-1})(\mathbf{x}_{k-1} - \mathbf{x}^{-}_{k-1})^T] \mathbf{A}_{k-1}^T + \mathbf{Q}_k$$

$$\mathbb{E}[\mathbf{w}_k \mathbf{w}_k^T] \mathbf{A}_{k-1}^T + \mathbf{Q}_k$$

更新

对于更新部分，我们将状态与 k 时刻的测量写成联合高斯分布的形式：

$$p(\mathbf{x}_k, \mathbf{y}_k | \mathbf{x}^{-}_0, \mathbf{v}_1:k, \mathbf{y}_0:k-1) = \mathcal{N}(\mathbf{x}_k | \mathbf{P}^{-}_k \mathbf{C}_k^T \mathbf{C}_k \mathbf{P}^{-}_k \mathbf{C}_k^T + \mathbf{R}_k)$$

由[高斯推断](#)可以直接得到 k 时刻的条件分布（即后验概率）：

$$p(\mathbf{x}_k | \mathbf{x}^{-}_0, \mathbf{v}_1:k, \mathbf{y}_0:k) = \mathcal{N}(\mathbf{x}_k | \mathbf{P}^{-}_k \mathbf{C}_k^T \mathbf{C}_k \mathbf{P}^{-}_k \mathbf{C}_k^T + \mathbf{R}_k)$$

$$\mathbf{P}^{-}_k = \mathbf{P}^{-}_{k-1} \mathbf{A}_{k-1}^T + \mathbf{Q}_k$$

$$\mathbf{P}^{-}_k = \mathbf{P}^{-}_{k-1} \mathbf{A}_{k-1}^T + \mathbf{Q}_k$$

令 $\mathbf{K}_k = \mathbf{P}^{-}_k \mathbf{C}_k^T (\mathbf{C}_k \mathbf{P}^{-}_k \mathbf{C}_k^T + \mathbf{R}_k)^{-1}$

$$\mathbf{x}^{+}_k = \mathbf{x}^{-}_k + \mathbf{K}_k (\mathbf{y}_k - \mathbf{C}_k \mathbf{x}^{-}_k)$$

$$\mathbf{P}^{+}_k = (\mathbf{I} - \mathbf{K}_k \mathbf{C}_k) \mathbf{P}^{-}_k$$

即证。