

迭代扩展卡尔曼滤波IEKF

预测

迭代扩展卡尔曼滤波（IEKF）的预测部分和[扩展卡尔曼滤波](#)基本相同。直接给出结论：

$$\begin{aligned} \hat{x}^k &= f(\hat{x}^{k-1}, v_k, 0) \\ P^k &= F_k - 1 P^{k-1} F_k - 1 T + Q_k \\ P^k &= F_k - 1 P^{k-1} F_k - 1 T + Q_k \end{aligned}$$

更新

非线性观测模型为：

$$y_k = g(x_k, n_k)$$

对其中任意一个点 $x_{op,k}$ 进行线性化，可得：

$$g(x_k, n_k) \approx y_{op,k} + G_k (x_k - x_{op,k}) + n_k$$

其中：

- $y_{op,k} = g(x_{op,k}, 0)$
- $G_k = \frac{\partial g(x_k, n_k)}{\partial x_k} \bigg|_{x_{op,k}, 0}$
- $n_k = \frac{\partial g(x_k, n_k)}{\partial n_k} \bigg|_{x_{op,k}, 0}$

任意一个点 $x_{op,k}$ 进行线性化，可得：

需要注意的是，观测模型和雅可比矩阵均在 $x_{op,k}$ 处计算。（在EKF中， $x_{op,k} = \hat{x}^k$ ）

使用上面的线性化模型，我们可以将时刻 k 处的状态和测量的联合概率近似为高斯分布，即：

$$p(x_k, y_k | x^0, v_{1:k}, y_{0:k-1}) \approx N(\mu_k, \Sigma_k)$$

如果测量值 y_k 已知，我们可以利用高斯推断得到 x_k 的条件概率密度（即后验）：

$$p(x_k | x^0, v_{1:k}, y_{0:k}) = N(\mu_k, \Sigma_k)$$

$$\mu_k = \Sigma_k \Sigma_{yy,k}^{-1} (y_k - \mu_{y,k}) + P^k$$

$$K_k = \Sigma_{xy,k} \Sigma_{yy,k}^{-1} = P^k G_k T (G_k P^k G_k T + R_k)^{-1}$$

$$P^k = (I - K_k G_k) P^k$$

$$\hat{x}^k = \hat{x}^k + K_k (y_k - y_{op,k} - G_k (\hat{x}^k - x_{op,k}))$$

可以看出，IEKF中的卡尔曼增益和更新方程与EKF非常相似，唯一的区别在于线性化的工作点。**如果将线性化的工作点设置为预测先验的均值**（即 $x_{op,k} = \hat{x}^k$ ），那么IEKF就等价于EKF。

然而，如果我们迭代的重新计算 \hat{x}^k ，并且在每一次迭代中将工作点设置为上一次迭代的后验均值（即令 $x_{op,k} = \hat{x}^k$ ），将得到更好的结果。

在第一次迭代中，我们令 $x_{op,k} = \hat{x}^k$ ，这使得我们能够对更好的估计进行线性化，从而改进每次迭代的近似程度。在迭代的过程中，若 $x_{op,k}$ 的改变足够小就终止迭代。

注意，卡尔曼增益方程和更新方程收敛之后，协方差方程只需要计算一次。